

アジェンダ

1. 講義

- アウトライン
- 数学的定式化
 - データ形式の説明
 - ロジスティック回帰モデルの説明
 - パラメータの推定
 - モデルの評価

2. ハンズオン

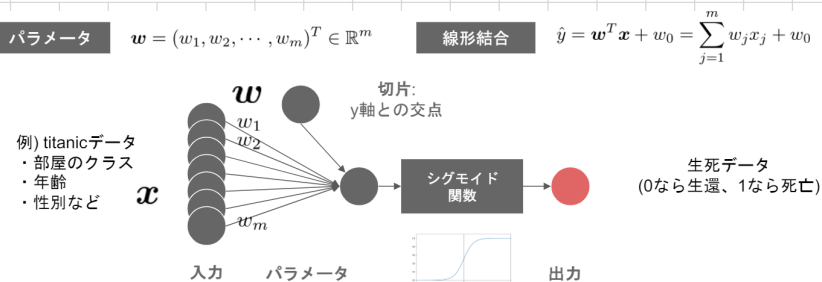
- タイタニックデータ解析
- 特徴量抽出分類タスクロジスティック回帰モデル

ロジスティック回帰モデル

分類問題(クラス分類): 入力~クラスに分類する問題。

入力: 説明変数: $x = (x_1, x_2, \dots, x_m)^T$: m 次元のベクトル($m=1$ の場合はスカラー)

出力: 目的変数: $y \in \{0 \text{ or } 1\}$



シグモイド関数


入力の実数・出力は必ず0~1の値

クラス1に分類される確率を表現


単調増加関数

- パラメータが変わるとシグモイド関数の形が変わる
 - a を増加させると, $x=0$ 付近での曲線の勾配が増加
 - a を極めて大きくすると, 単位ステップ関数($x < 0$ で $f(x)=0$, $x > 0$ で $f(x)=1$ となるような関数)に近づきます
 - バイアス変化は段差の位置


$$\sigma(x) = \frac{1}{1 + \exp(-ax)}$$




$a=0.2$



$a=0.5$



$a=1$



$a=10$

シグモイド関数の微分は、シグモイド関数自身で表現することが可能。

尤度関数の微分を行う際にこの事実を利用すると計算が容易。

$$\begin{aligned} \frac{\partial \sigma(x)}{\partial x} &= \frac{\partial}{\partial x} \left(\frac{1}{1 + \exp(-ax)} \right) \\ &= (-1) \cdot \{1 + \exp(-ax)\}^{-2} \cdot \exp(-ax) \cdot (-a) \\ &= \frac{a \exp(-ax)}{\{1 + \exp(-ax)\}^2} = \frac{a}{1 + \exp(-ax)} \cdot \frac{1 + \exp(-ax) - 1}{1 + \exp(-ax)} \\ &= a \sigma(x) (1 - \sigma(x)) \end{aligned}$$

連鎖律

$y = \frac{f(x)}{g(x)}$ の導関数は

$$y' = \frac{f'(x)g(x) - f(x)g'(x)}{\{g(x)\}^2}$$

【指数関数の微分 公式1】

$$y = e^x \rightarrow y' = e^x$$

$$y = e^{kx} \rightarrow y' = k e^{kx}$$

$$\text{sigmoid}(x) = 1 / \{1 + \exp(-ax)\}$$

$$\text{sigmoid}(x)' = a * \text{sigmoid}(x) * \{1 - \text{sigmoid}(x)\}$$

ロジスティック回帰でのモチベーション: シグモイド関数を利用して、 $Y=1$ となるような関数を求めたい。

求めたい値

シグモイド
関数

$$P(Y = 1 | \mathbf{x}) = \sigma(w_0 + w_1 x_1 + \dots + w_m x_m)$$

説明変数の実現値が
与えられた際に $Y=1$ になる確率

データのパラメーターに対する線形結合

最尤推定

ベルヌーイ分布: コイン投げイメージの確率分布

最尤推定: 得られたデータからもっともらしい母数分布を推定する方法 → 尤度関数を最大化する。

同時確立: あるデータが得られたときに、それが同時に得られる確率

尤度関数: データは固定し、パラメータを変化させる。

1回の試行で
 $y=y_1$ になる確率

$$P(y) = p^y (1-p)^{1-y}$$

: 既知

: 未知

n回の試行で
 $y_1 \sim y_n$ が同時に
起こる確率(p固定)

$$P(y_1, y_2, \dots, y_n; p) = \prod_{i=1}^n p^{y_i} (1-p)^{1-y_i}$$

$y_1 \sim y_n$ のデータが
得られた際の
尤度関数

$$P(y_1, y_2, \dots, y_n; p) = \prod_{i=1}^n p^{y_i} (1-p)^{1-y_i}$$

※尤もらしいPを求める!

確率pはシグモイド関数となるため、推定するパラメータは重みパラメータとなる

ロジスティック回帰モデルの最尤推定

- 確率pはシグモイド関数となるため、推定するパラメータは重みパラメータとなる
- $(x_1, y_1), (x_2, y_1), \dots, (x_n, y_n)$ を生成するに至った尤もらしいパラメータを探す

$$P(Y = y_1 | x_1) = p_1^{y_1} (1-p_1)^{1-y_1} = \sigma(w^T x_1)^{y_1} (1 - \sigma(w^T x_1))^{1-y_1}$$

$$P(Y = y_2 | x_2) = p_2^{y_2} (1-p_2)^{1-y_2} = \sigma(w^T x_2)^{y_2} (1 - \sigma(w^T x_2))^{1-y_2}$$

...

$$P(Y = y_n | x_n) = p_n^{y_n} (1-p_n)^{1-y_n} = \sigma(w^T x_n)^{y_n} (1 - \sigma(w^T x_n))^{1-y_n}$$

: 既知

: 未知

★ x_i が具体的にイメージがわからない。

推察:

$0 < x < 1$ な固定値で(なんでもよい)のか?

$0 < x < 1$ な固定値を w_i の学習で制御する考えか?

★尤度関数


★推察: Pの引数は y_i だけでなく、 x_i も含む。でよいのか? (x_i を与えると y_i となるような w_i を求めていく?)

$$\begin{aligned} P(y_1, y_2, \dots, y_n | w_0, w_1, \dots, w_m) &= \prod_{i=1}^n p_i^{y_i} (1-p_i)^{1-y_i} \\ &= \prod_{i=1}^n \sigma(w^T x_i)^{y_i} (1 - \sigma(w^T x_i))^{1-y_i} \\ &= L(w) \end{aligned}$$

尤度関数は
パラメータのみに依存する関数

★対数尤度関数

- 尤度関数を最大とするパラメータを探す (推定)
 - 対数をとると微分の計算が簡単
 - 同時確率の積が和に変換可能
 - 指数が積の演算に変換可能
 - 対数尤度関数が最大になる点と尤度関数が最大になる点は同じ
 - 対数関数は単調増加 (ある尤度の値が $x_1 < x_2$ の時、必ず $\log(x_1) < \log(x_2)$ となる)
 - 「尤度関数にマイナスをかけたものを最小化」し、「最小2乗法の最小化」と合わせる



$$E(w_0, w_1, \dots, w_m) = -\log L(w_0, w_1, \dots, w_m)$$

$$= -\sum_{i=1}^n \{u_i \log u_i + (1-u_i) \log(1-u_i)\}$$

$$= - \sum_{i=1}^n \{ y_i \log p_i + (1 - y_i) \log (1 - p_i) \}$$

対数公式: $\log(A \times B) = \log A + \log B$
 $\log(A^B) = B \log A$

■勾配降下法

対数尤度関数をパラメータで微分して0になる値を求める必要があるのだが、解析的にこの値を求めることは困難

$$w(k+1) = w^k - \eta \frac{\partial E(w)}{\partial w}$$

★対数尤度関数の微分

対数尤度関数を係数とバイアスに関して微分

$$\begin{aligned} \frac{\partial E(w)}{\partial w} &= \sum_{i=1}^n \frac{\partial E_i(w)}{\partial p_i} \frac{\partial p_i}{\partial w} \\ &= \sum_{i=1}^n \left(\frac{y_i}{p_i} - \frac{1-y_i}{1-p_i} \right) \frac{\partial p_i}{\partial w} \\ &= \sum_{i=1}^n \left(\frac{y_i}{p_i} - \frac{1-y_i}{1-p_i} \right) p_i(1-p_i)x_i \\ &= - \sum_{i=1}^n (y_i(1-p_i) - p_i(1-y_i))x_i \\ &= - \sum_{i=1}^n (y_i - p_i)x_i \end{aligned}$$

連鎖律

対数尤度関数の
pに関する微分

シグモイド関数の微分

式を整理


確率的勾配降下法(SGD)

データを一つずつランダムに(「確率的」に)選んでパラメータを更新

勾配降下法でパラメータを1回更新するのと同じ計算量でパラメータをn回更新できるので効率よく最適な解を探索可能


$$w(k+1) = w^k + \eta(y_i - p_i)x_i$$

普通の勾配降下法：



確率的勾配降下法：

毎回の更新でデータの一つ(または少量)しか見ない



評価

学習済みの「ロジスティック回帰モデル」の性能を測る指標 → 混同行列

正解率(Accuracy) $(TP + TN) / (TP + TN + FP + FN)$

再現率(Recall) $TP / (TP + FN)$

		ラベル (答え)	
		positive	negative
モデルの 予測結果	positive	True Positive	False Positive
	negative	False Negative	True Negative

False Negative
が小さい

適合率(Precision) $TP / (TP + FP)$

		ラベル (答え)	
		positive	negative
モデルの 予測結果	positive	True Positive	False Positive
	negative	False Negative	True Negative

False Positive
が小さい

★要するに精度を上げたい分布を母数にする

F値(F-measure):調和平均 (※逆数の平均の逆数)

	メリット	デメリット
正解率	最もシンプルで分かりやすい	クラスごとの評価データ数が著しく異なると不適切
再現率	取りこぼしを発見できる	過検知を発見できない
適合率	過検知を発見できる	取りこぼしを発見できない
F値	取りこぼし、過検知をどちらも均等に判断できる	数値の解釈が難しくなる

←過検知してよいケース
ウイルス感染検査など
過検知したら再検査すればいい。
←取りこぼしてよいケース
スパムメール検知など。
取りこぼしたら自分で分類する。