

★主に以下の動画にて学習

<https://www.youtube.com/watch?v=cNEhKEb9-JU>

<https://www.youtube.com/watch?v=2IB7vkfGeAA>

<https://www.youtube.com/watch?v=fUSO6-0o3ds>

サポートベクターマシン(SVM)

「Support Vector」とは、データを分割する直線に最も近いデータ点の事

サポートベクターを定めてこのような分割線が決まれば、あとはコレより上にあるか下にあるかで、どのクラスに属しているかの予測が出来る。

SVMの肝は、マージン最大化とカーネル法により非線形データを扱えるところ。

● SVMのメリット

データの次元が大きくなっても識別精度が良い

最適化すべきパラメータが少ない

● SVMのデメリット


学習データが増えると計算量が膨大になる

基本的に2クラス分類に特化している

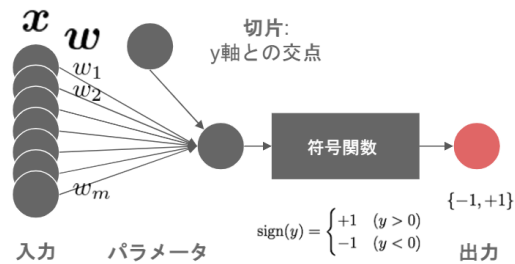
スケーリングが必要

(SVMでは距離を測定するので、大きい範囲をとる特徴量に引きずられないようにする)

$$y = w^T x + b = \sum_{i=1}^m w_i x_i + b$$




決定境界はいくつも考えられる




●「線形判別関数と最も近いデータ点との距離」を「マージン」という

●マージンが最大となる線形判別関数を求める





線形判別関数 $w^T x + b = 0$



マージンをパラメータに依存する関数として表現！

■ 目的関数の導出(準備)



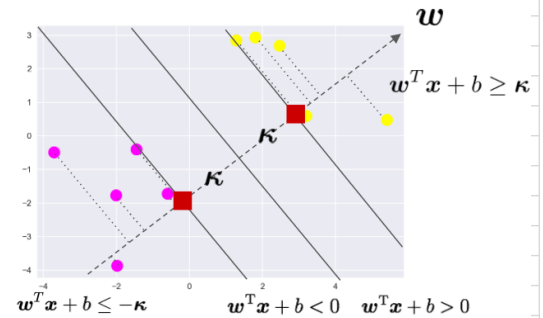
各クラスのデータをwの方向kへ射影した点
w軸に座標を変換

線形判別関数のマージンをκとした時に
全てのデータ点でなりたつ条件
(特に路肩上のデータに対してはκが成り立つ)

標準座標系に修正！

$$|w^T x + b| \geq \kappa$$

$$\begin{aligned} \rho(w, b) &= \min_{x \in C_{t_i=+1}} \frac{w^T x_i}{\|w\|} - \max_{x \in C_{t_i=-1}} \frac{w^T x_i}{\|w\|} \\ &= \frac{1 - b}{\|w\|} - \frac{-1 - b}{\|w\|} \\ &= \frac{2}{\|w\|} \end{aligned}$$



wが決まればマージン
が決まる

<https://manabitimes.jp/math/857>

点 $A(x_0, y_0)$ と直線 $l: ax + by + c = 0$ の距離 d は,

$$d = \frac{|ax_0 + by_0 + c|}{\sqrt{a^2 + b^2}}$$


各点と決定境界との距離は、点と直線との距離の公式から
例えば: <https://mathtrain.jp/tentotyokusen>

$$\frac{|w^T x_i + b|}{\|w\|} = \frac{t_i(w^T x_i + b)}{\|w\|}$$

絶対値の定義より

マージンとは決定境界と最も距離の近い点との
距離なので、

$$\min_i \frac{t_i(w^T x_i + b)}{\|w\|}$$




SVMはマージンを最大化することを目標なので目的関数は

$$\max_{w, b} \left[\min_i \frac{t_i(w^T x_i + b)}{\|w\|} \right]$$

マージンが最大となる直線(パラメータ)を探す


マージン上の点において、 $t_i(w^T x_i + b) = 1$
が成り立つため、すべての点に対して、
 $t_i(w^T x_i + b) \geq 1$ が成り立ち、目的関数は
以下になる。

$$\begin{aligned} t_j(w^T x_j + b) &= 1 & t_i(w^T x_i + b) &= 1 \\ t_j(w^T x_j + b) &> 1 & t_i(w^T x_i + b) &> 1 \end{aligned}$$



$$\max_{w,b} \frac{1}{\|w\|}$$

マージンで正規化すると
成り立つ



サポートベクターマシンにおける主問題と双対問題

SVMの主問題

- 主問題の目的関数と制約条件

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$t_i(w^T x_i + b) \geq 1 \quad (i = 1, 2, \dots, n)$$

上の最適化問題をラグランジュ未定乗数法で解く

ラグランジュの未定乗数法

- 制約付き最適化問題を解くための手法

制約 $g_i(x) \geq 0 (i = 1, 2, \dots, n)$ のもとで、 $f(x)$ が最小となる x は、

変数 $\lambda_i \geq 0 (i = 1, 2, \dots, n)$ を用いて新たに定義したラグランジュ関数

$$L(x, \lambda) = f(x) - \sum_{i=1}^n \lambda_i g_i(x) \quad \text{において} \quad \frac{\partial L}{\partial x_j} = 0 \quad (j = 1, 2, \dots, m) \quad \text{を満たす}$$

カルーシュ・クーン・タッカー条件 (KKT条件)

KKT条件とは、「非線形計画において一階導関数が満たすべき最適条件」を指す。

※「ラグランジュの未定乗数法」が等式制約のみを扱うのに対して、「KKT条件を用いた解法」は不等式制約も扱うことができる。

KKT条件

- 制約付き最適化問題において最適解が満たす条件

制約 $g_i(x) \geq 0 (i = 1, 2, \dots, n)$ のもとで、 $f(x)$ が最小となる x^* は、以下の条件を満たす

$$\frac{\partial L}{\partial x_j} \Big|_{x^*} = 0 \quad (j = 1, 2, \dots, m)$$

不等式制約でも満たすようになる

$$g_i(x^*) \leq 0, \quad \lambda_i \geq 0, \quad \lambda_i g_i(x^*) = 0 \quad (i = 1, 2, \dots, n)$$

(Lはラグランジュ関数、 λ はラグランジュ乗数である)

ラグランジュの未定乗数法

$$\text{ラグランジュ関数} \quad L(w, b, a) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^n a_i (t_i(w^T x_i + b) - 1)$$

$a_i \geq 0 (i = 1, 2, \dots, n)$ はラグランジュ乗数である。
そして、最小となる w, b は以下を満たす。

AT.

n

n

$$\begin{aligned}\frac{\partial L}{\partial \mathbf{w}} &= \mathbf{w} - \sum_{i=1}^n a_i t_i \mathbf{x}_i = 0 \\ \frac{\partial L}{\partial b} &= -\sum_{i=1}^n a_i t_i = 0\end{aligned}$$



$$\begin{aligned}\mathbf{w} &= \sum_{i=1}^n a_i t_i \mathbf{x}_i \\ \sum_{i=1}^n a_i t_i &= 0\end{aligned}$$

不明点: ???wがゼロになってしまうが。。。

双対問題

- ・ ラグランジュ関数から \mathbf{w}, b を消去

$$\begin{aligned}\tilde{L} &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n a_i (t_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) \\ &= \frac{1}{2} \left(\sum_{i=1}^n a_i t_i \mathbf{x}_i \right)^T \left(\sum_{j=1}^n a_j t_j \mathbf{x}_j \right) - \sum_{i=1}^n a_i t_i \left(\sum_{j=1}^n a_j t_j \mathbf{x}_j \right)^T \mathbf{x}_i - b \sum_{i=1}^n a_i t_i + \sum_{i=1}^n a_i \\ &= \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j t_i t_j \mathbf{x}_i^T \mathbf{x}_j\end{aligned}$$

- ・ 双対問題の目的関数と制約条件

$$\begin{aligned}\max_{\mathbf{a}} \quad & \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j t_i t_j \mathbf{x}_i^T \mathbf{x}_j \\ & \sum_{i=1}^n a_i t_i = 0 \\ & a_i \geq 0 \quad (i = 1, 2, \dots, n)\end{aligned}$$

主問題と双対問題

- ・ 主問題の最適解と双対問題の最適解は一対一対応

$$\begin{aligned}\mathbf{w} &= \sum_{i=1}^n a_i t_i \mathbf{x}_i \\ b &= \frac{1}{t_i} - \mathbf{w}^T \mathbf{x}_i \quad (\text{KKT条件の相補性条件 } a_i (t_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) = 0 \text{ より} \\ & \quad a_i > 0 \text{ となる } i \text{ に対して})\end{aligned}$$

■予測

予測

- ・ SVMの決定関数


$$y(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b = \sum_{i=1}^n a_i t_i \mathbf{x}_i^T \mathbf{x} + b$$

KKT条件の相補性条件 $a_i (t_i (\mathbf{w}^T \mathbf{x}_i + b) - 1) = 0$ から、

- ・ $t_i (\mathbf{w}^T \mathbf{x}_i + b - 1) > 0$ のとき、つまりマージンの外側のデータでは $a_i = 0$ となり予測に影響を与えない。
- ・ $t_i (\mathbf{w}^T \mathbf{x}_i + b - 1) = 0$ のとき、つまりマージン上にあるデータでは $a_i > 0$

となり、予測に影響を与える。(サポートベクター)

・分離超平面を構成する学習データは、サポートベクターだけで残りのデータは不要




ハードマージンSVM:線形分離可能な場合

ソフトマージンSVM

- サンプルを線形分離できないとき
- 誤差を許容し、誤差に対してペナルティを与える

ξ :クサイ

マージン内に入るデータや誤分類されたデータに対して誤差を表す変数 ξ_i を導入する



ソフトマージンSVMの目的関数と制約条件

ソフトマージンSVMの目的関数と制約条件は以下のようになる

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

マージンの大きさ

誤差に対するペナルティ

トレードオフを制御するパラメータ

双対表現

$$\max_a \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j t_i t_j x_i^T x_j$$


$$\sum_{i=1}^n a_i t_i = 0$$

$$0 \leq a_i \leq C \quad (i = 1, 2, \dots, n)$$


$$t_i(w^T x + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

ソフトマージンSVM

- 線形分離できない場合でも対応
- パラメータCの大小で決定境界が変化




Cが小さい時 (誤差をより許容する)




Cが大きい時 (誤差をあまり許容しない)

非線形分離

- ・ 線形分離できないとき
- ・ 特徴空間に写像し、その空間で線形に分離する




線形に分離できない



特徴空間に
写像 $\phi(x)$

特徴空間上では
線形に分離可能



もとの空間上では
非線形な分離

カーネルトリック

目的関数は以下のように変わる

$$\max_{\alpha} \sum_{i=1}^n a_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n a_i a_j t_i t_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

ここのみ変化

カーネルトリック

- ・ カーネル関数 $k(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$
- ・ 高次元ベクトルの内積をスカラー関数で表現
- ・ 特徴空間が高次元でも計算コストを抑えられる

非線形カーネルを用いた分離

- ・ 非線形な分離が可能

放射基底関数カーネル (RBFカーネル・ガウシアンカーネル) を用いる

$$k(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$$

